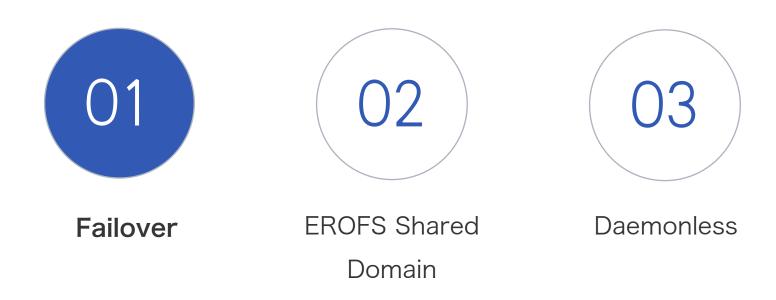
# New Features

字节跳动基础架构部内核与虚拟化团队 祝嘉

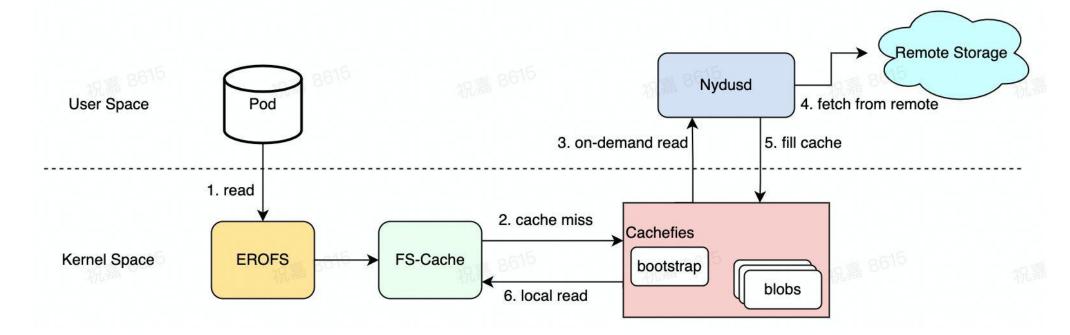
# 实践与探索——New Features



## 稳定性提升: User Daemon Failover

#### 背景:

- 用户态进程crash后,IO请求将返回错误,影响容器中运行的业务 预期目标:容器不感知用户态进程crash/restart
- In-Flight IO不丢失
- User Daemon crash后 ~ 重启前 产生的IO不丢失
- IO在有限时间内恢复



### lul ByteDance字节跳动

## 稳定性提升: User Daemon Failover

#### 方案设计

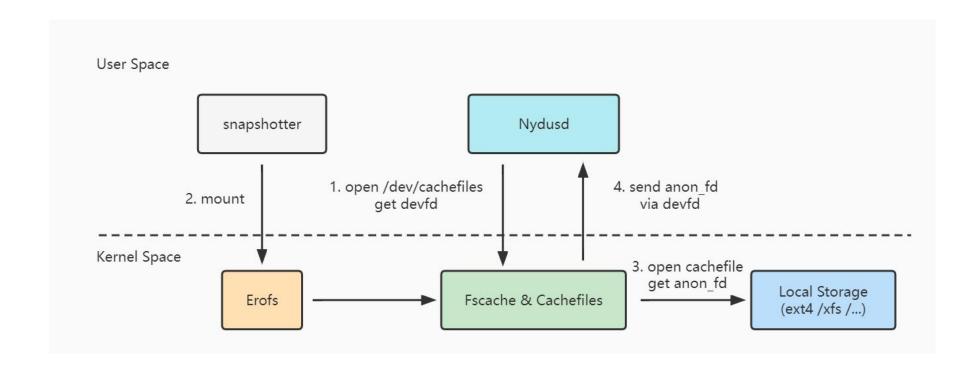
- 异常监控
  - 用户态 supervisor 监控 user daemon 状态, 触发故障恢复流程
- 资源保持与恢复
  - 控制面: /dev/cachefiles fd的保持和传递(UDS)
  - 数据面: Reopen mechanism: 由按需IO驱动重新发送 anonymous fd
  - cachefiles 'restore' cmd: 触发恢复In-Flight IO

### In ByteDance字节跳动

## 稳定性提升: User Daemon Failover

## fd资源保持与恢复

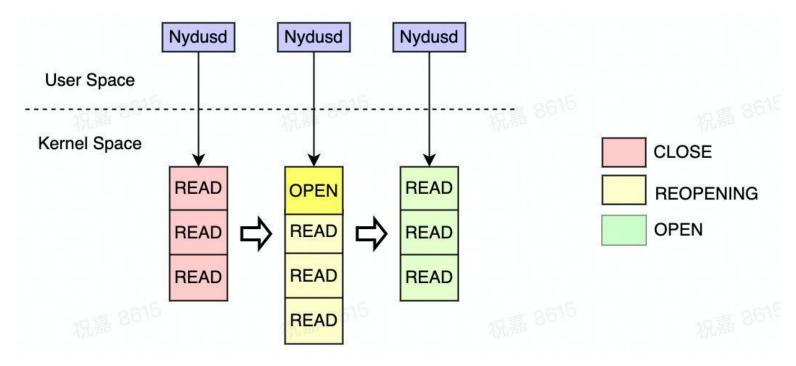
• /dev/cachefiles fd: 用户态使用UDS保存和恢复



## 稳定性提升: User Daemon Failover

#### fd资源保持与恢复

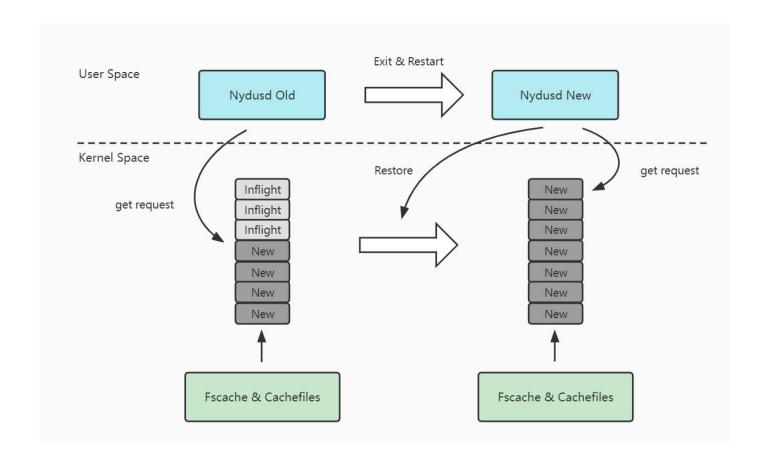
• 缓存文件匿名fd: 由按需IO触发, 重新生成OPEN请求打开文件



IO request xaray

## 稳定性提升: User Daemon Failover

• 恢复IO请求



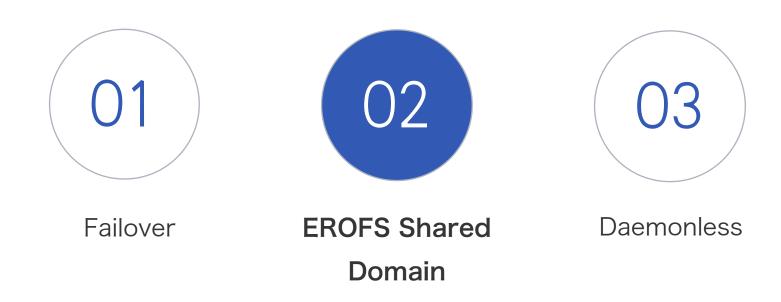
## li ByteDance字节跳动

## 稳定性提升: User Daemon Failover

•进展: 正在推动进入upstream

•https://lore.kernel.org/all/20221014080559.42108-1-zhujia.zj@bytedance.com/

# 实践与探索——New Features



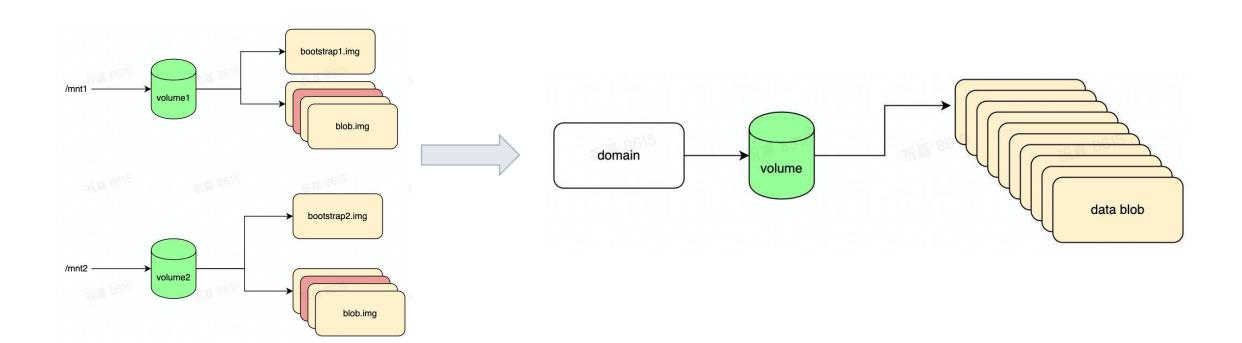
## 数据去重: EROFS Shared Domain

#### 背景:

• 不同EROFS挂载点间,相同的镜像无法共享

## 预期目标:

• 实现镜像layer粒度的共享



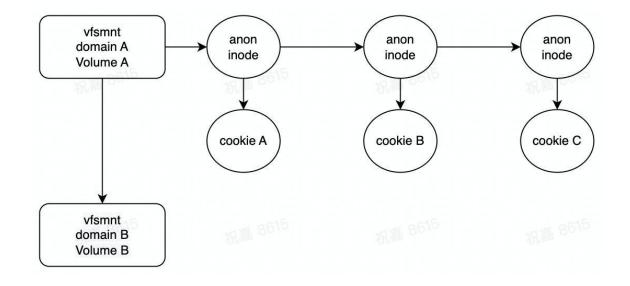
## 数据去重: EROFS Shared Domain

#### 设计

- EROFS侧抽象Shared Domain模型,对应fscache volume
- pseudo挂载点
  - 管理domain生命周期
  - anonymous inodes 管理镜像文件生命周期,对应 fscache cookie (blob)

#### 使用

- EROFS挂载选项'domain\_id'
- 创建/加共享域: 同一共享域内所有挂载点共享镜像
- 不使用domain id: 不与任何挂载点共享镜像数据



## 数据去重: EROFS Shared Domain

CACHE	REF V	/0LS	0BJS	ACCI	es s na	AME																				
00000007	2					acheFil		=			Share	ed Dom	ain													
VOLUME		nC00K					KEY																			
00000007	8	7			cheFile		erofs	,ABigDom	nain																	
C00KIE	VOLUME				S FL DE = == ==	:F		==																		
0000001a	0000000	97 2	1	0 /	A 6134	376561	3139336	62343333	636164	363264	3162393	039656	3643661	3934383	230316	662313	766663	564326	163613	33238	343135	346261	64303	930313	303962	313836
0000001b	0000000	97 2	1	0 /	A 6134	353132	6530666	64646564	613130	653366	3337636	135633	7303137	3261653	931326	134616	664323	133366	337393	323837	343365	386134	66363	035663	373138	656264
0000001c	0000000	97 2	1	0 /	A 4134	633733	333861	36343862	316332	636362	3533646	137373	5616664	3462323	463346	663666	133353	839353	735383	46230	356632	633934	38333	634633	306361	356662
0000001d	0000000	97 2	1	0 /	A 4134	636238	3431383	34613633	643962	336234	3339366	339616	2626665	6131323	066643	661356	537353	132663	933626	43132	633939	346466	37613	430633	303937	623535
0000001e	0000000	97 2	1	0 /	A 6134	353937	333165	32336265	333761	616335	3363366	465643	1383934	3464663	434313	536616	131343	131326	234343	63964	363234	323166	61646	463363	393937	343532
0000001f	0000000	97 2	1	0 /	A 6134	323634	323461	38323633	356431	353761	6233323	766613	5623637	3764633	131646	536353	563666	132666	338303	83965	663032	373564	33333	464366	543430	623237
00000020	0000000	97 2	1	0 /	A 6134	333265	3732656	66383534	643438	643438	3530663	664363	7376235	6130383	564633	235636	436393	235303	132393	63336	616530	636438	33323	266373	373232	323031

### **In** ByteDance字节跳动

## 数据去重: EROFS Shared Domain

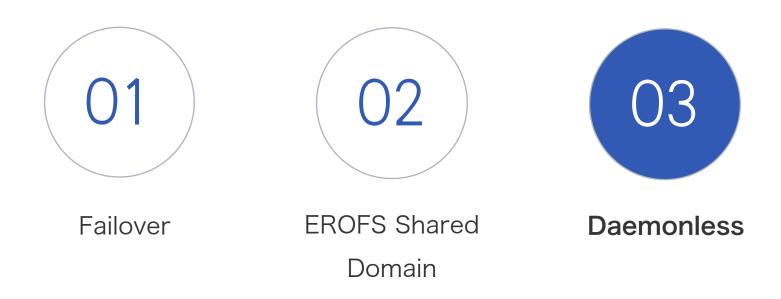
#### •进展

- 已进入upstream v6.1-rc1
- https://lore.kernel.org/all/20220916085940.89392-1zhujia.zj@bytedance.com/

#### •未来工作

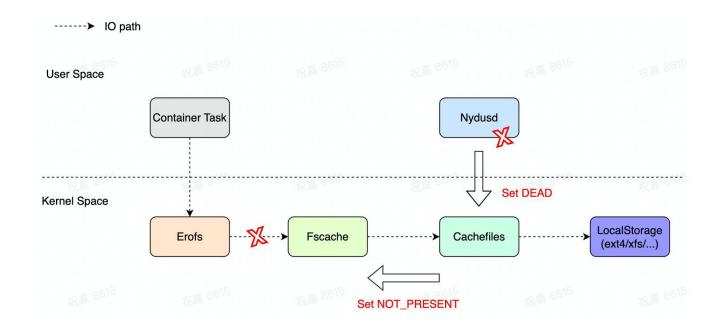
• 发挥内核文件系统优势,探索page cache sharing

# 实践与探索——New Features



## O开销: Daemonless

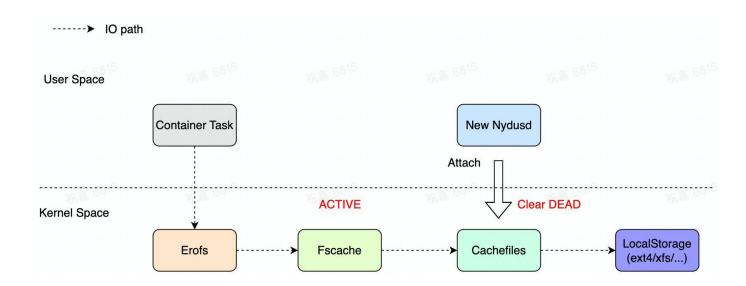
- •背景:按需加载完成后,IO转为纯内核路径,不再需要用户进程参与,可使其退出,节省资源
- •面临的挑战:用户进程退出后,fscache相关内核结构被置为DEAD状态,EROFS无法从fscache中读取数据
- •设计目标: cachefiles实现新运行模式, 解除本地数据访问对user daemon的依赖



## O开销: Daemonless

#### 设计目标

- •daemon 退出后,内核不释放相关结构,EROFS依然可以访问本地缓存 文件
- •daemon启动,可重新接管上述本地缓存文件,继续进行cache维护管理。



## In ByteDance字节跳动

## O开销: Daemonless

## 进展

代码已验证完成, 即将提交内核社区

# Thanks